信息瓶颈理论介绍

何扬槊

College of Information Science and Electronic Engineering

信息与电子工程学院

Zhejiang University

浙江大学

9 Jun 2024

引言

- 由香农提出的**信息论**是研究存储、传输、处理信息的数学理论，是通信和数据压缩的基础。
- 传统信息论关注信息的压缩速率，但不考虑其内容的含义。
- 在信息压缩过程中，不是所有信息都是有用的，Tishby 提出**信息瓶颈 (IB) 理论** [1] 试图找到对目标重要的信息。
- IB 提供了理解信息压缩的新视角，关注与信息与任务的相关性。
- IB 也提供了一个理解**神经网络**如何筛选和压缩信息的框架。

Outline 目录

引言

背景

IB 理论

IB 与神经网络

参考文献

浙江大学 信息与电子工程学院
College of Information Science & Electronic Engineering, Zhejiang University

信息论回顾

- 互信息：

$$I(X;\ Y) = \sum_{x,y} p(x,\ y) \log \frac{p(x|y)}{p(x)}. \tag{1}$$

- KL 散度：

$$D(p\|q) = \sum_{x} p(x) \log \frac{p(x)}{q(x)}. \tag{2}$$

- 率失真理论：

$$R(D) = \min_{p(\hat{x}|x):\sum_{(x,\hat{x})} p(x)p(\hat{x}|x)d(x,\hat{x}) \le D} I(X;\hat{X}). \tag{3}$$

浙江大学 信息与电子工程学院
College of Information Science & Electronic Engineering, Zhejiang University

率失真

- 率失真理论是香农信息论的一个重要分支，研究在有损压缩中以尽可能小的失真传输信息。
- 把率失真函数重写为拉格朗日函数形式：

$$R(D) = \min_{p(t|x):d(x,\hat{x})\leq D} I(X;\hat{X}), \tag{4}$$

$$L = I(X;\hat{X}) + \beta d(x,\hat{x}). \tag{5}$$

- 率失真理论对信息压缩和信息失真之间进行权衡，核心目标是给定失真下的最优压缩速率，其最优解为：

$$p^*(\hat{x}|x) = \frac{p(\hat{x})}{Z(x,\beta)} \exp(-\beta d(x,\hat{x})). \tag{6}$$

浙江大学 信息与电子工程学院
College of Information Science & Electronic Engineering, Zhejiang University

Outline 目录

引言

背景

IB 理论

IB 与神经网络

参考文献

浙江大学 信息与电子工程学院
College of Information Science & Electronic Engineering, Zhejiang University

IB 概述

- 为了弥补信息论的不足，Tishby 提出了信息瓶颈 (IB) 理论 [1]。
- IB 理论的核心是找到一个“瓶颈”，使其包含输入中与输出相关的信息。
- 定义输入为 X，输出为 Y，“瓶颈”为 T，则信息压缩的过程可以表示为马尔科夫链 $X \to T \to Y$。

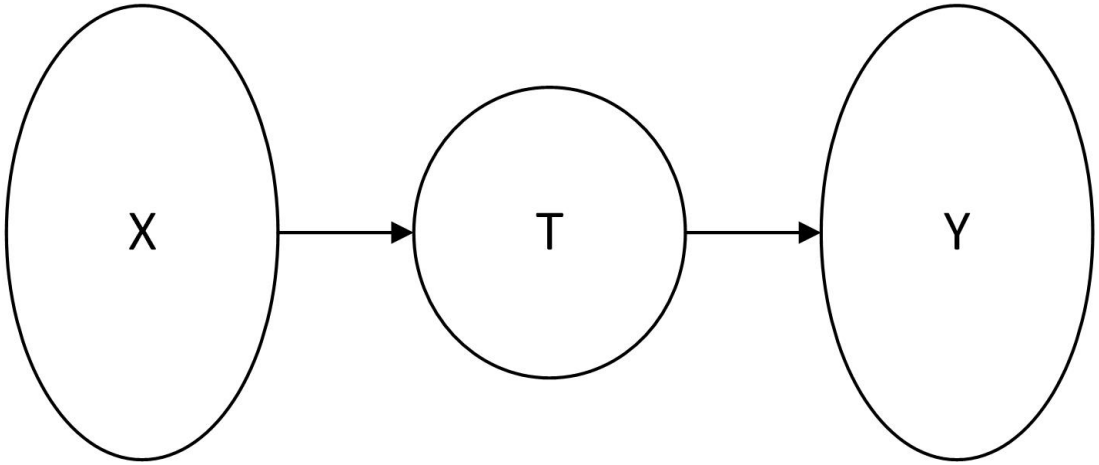

图. 1. 信息提取

浙江大学 信息与电子工程学院
College of Information Science & Electronic Engineering, Zhejiang University

IB 概述

- 瓶颈 T 可以视作输入数据 X 中与输出 Y 相关的特征。
- 压缩过程：$I(X;T)$ 衡量压缩的质量，表示输入所需的比特数。
- 任务推理：$I(X;Y)$ 为输出关于输入的信息论，表示输出的质量。
- 由马尔科夫链的性质，$I(T;Y) \leq I(X;Y)$。
- 两个互信息理解为压缩的**复杂度**$I(X;T)$ 和输出的**相关性** $I(T;Y)$。
- IB 通过优化两者的 trade-off，寻找最优的特征表示 T。

浙江大学 信息与电子工程学院
College of Information Science & Electronic Engineering, Zhejiang University

IB 优化目标

- IB 核心目标是找到一个最优表示 T，压缩输入数据并保留与任务相关的信息。
- 在保留关于输出 Y 的有意义信息的同时，最小化来自输入 X 的比特数。
- 因此，IB 定义了一个**目标函数**：

$$\mathcal{L}_{IB} = I(X;T) - \beta I(T;Y). \tag{7}$$

- β 作为信息压缩和保留之间的权衡参数。

浙江大学 信息与电子工程学院
College of Information Science & Electronic Engineering, Zhejiang University

IB 优化目标

- 找到最优的压缩表示 T，即根据输入找到最优的条件分布 $p(t \mid x)$，以最小化目标 $\mathcal{L}_{IB}$。

$$\begin{aligned} \min_{p(t|x)} \quad & I(X;T) - \beta I(T;Y) \\ s.t. \quad & \sum_T p(t \mid x) = 1 \end{aligned} \tag{8}$$

- [1] 利用拉格朗日乘子法，推导得到了最优解的解析式。

$$p^*(t \mid x) = \frac{p(t)}{Z(x,\beta)} \exp\left[-\beta \sum_y p(y \mid x) \log \frac{p(y \mid x)}{p(y \mid t)}\right] \tag{9}$$

- $Z(x,\beta) = \sum_t p(t) \exp\left(-\beta D\left[p(y|x) \| p(y|t)\right]\right)$ 为归一化函数。
- 根据贝叶斯法则，推理过程为 $p(y|t) = \frac{1}{p(t)} \sum_x p(y|x)p(t|x)p(x)$。

浙江大学 信息与电子工程学院
College of Information Science & Electronic Engineering, Zhejiang University

IB 求解

- IB 的最优解中，$p(t|x)$ 和 $p(y|t)$ 循环表示，需要通过迭代求解。

$$\begin{cases} p_i(t|x) = \frac{p_i(x)}{Z(x,\beta)} \exp(-\beta d(x,t)) \\ p_{i+1}(t) = \sum_x p(x) p_i(t|x) \\ p_{i+1}(y|t) = \sum_y p(y|x) p_i(x|t) \end{cases}$$

- **Remark** 对比率失真理论可以发现，KL 散度 $D\left[p(y|x)\|p(y|t)\right]$ 可以作为 IB 框架中度量压缩失真的指标 $d(x,t)$。
- **Remark** 率失真和 IB 都研究了信息压缩和信息保留的 trade-off，但 IB 更关注于压缩表征中与任务相关的信息。

Outline 目录

引言

背景

IB 理论

IB 与神经网络

参考文献

浙江大学 信息与电子工程学院
College of Information Science & Electronic Engineering, Zhejiang University

神经网络

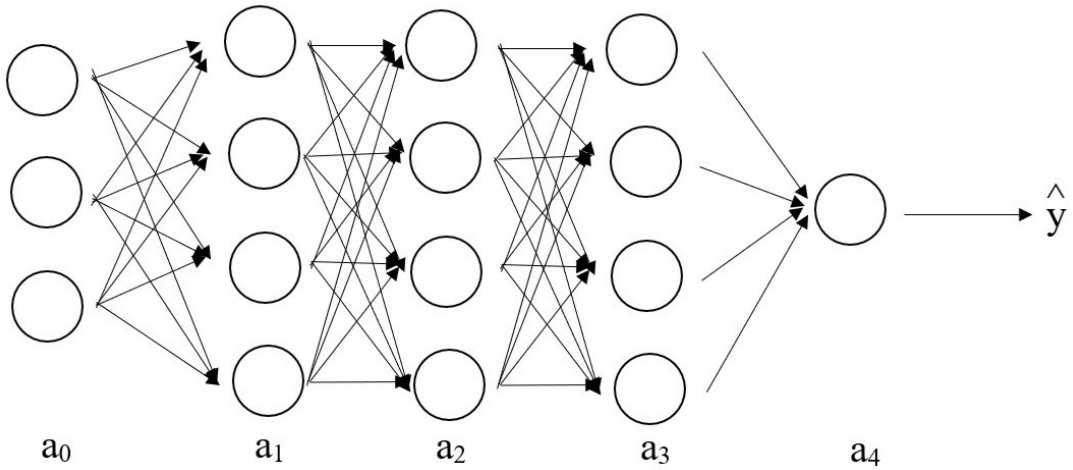

图. 2. 神经网络构示意图

神经网络的权重更新可以写成优化问题：

$$
\begin{aligned}
(w,\ b)^* &= \underset{(w,\ b)}{\text{argmin}}\ loss(a^{[L]},\ y) \\
a^{[l]} &= \sigma(w^{[l]}a^{[l-1]} + b^{[l]}),\ l = 1, \cdots, L
\end{aligned}
\tag{10}
$$

神经网络

更一般地，可以用极大似然估计来表示优化问题：

$$(w,\ b)^* = \underset{(w,\ b)}{\text{argmax}}\ \frac{1}{m}\sum_{i=1}^{m}\log P_{Y|X}(y_i|x_i) \tag{11}$$

或者利用 KL 散度来描述：

$$(w,\ b)^* = \underset{(w,\ b)}{\text{argmin}}\ D_{KL}(P_{XY}\|P_X P_{Y|X}) \tag{12}$$

浙江大学 信息与电子工程学院
College of Information Science & Electronic Engineering, Zhejiang University

基于 IB 对 DNN 的理解

- [2] 把 DNN 当作一条马尔科夫链并理解为信息提取的过程，每一层都是对输入数据的压缩。
- 神经网络的数据处理过程被分为两个阶段：**数据拟合**与**信息压缩**。

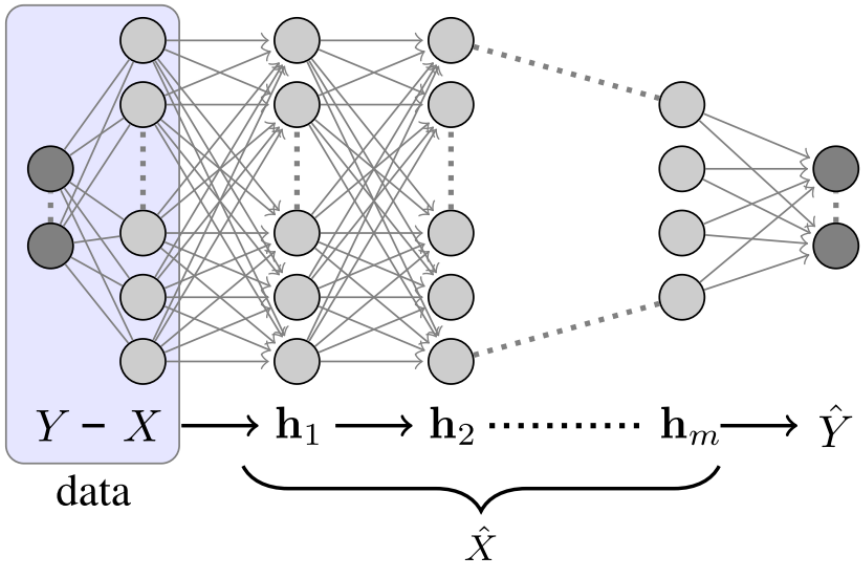

图. 3. DNN 示意图

浙江大学 信息与电子工程学院
College of Information Science & Electronic Engineering, Zhejiang University

基于 IB 对 DNN 的理解

- 拟合阶段：把所有信息都存储在隐藏层中，使得 $I(T;\ X)$ 尽可能大。
- 压缩阶段：丢弃任务无关的信息，使得 $I(T;\ Y)$ 尽可能大，同时 $I(T;\ X)$ 尽可能小。

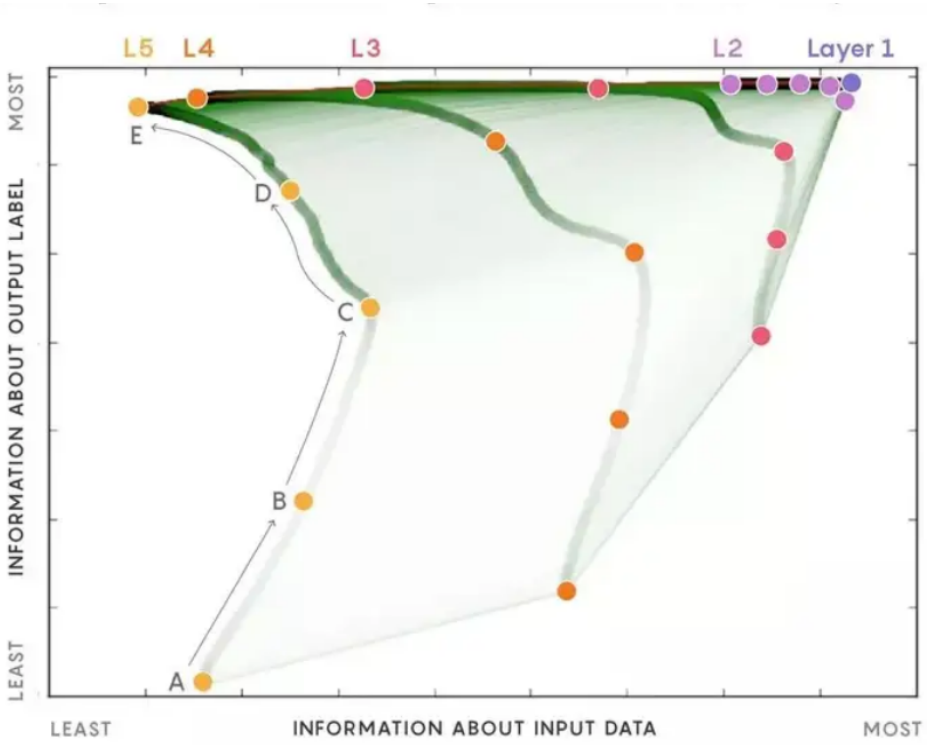

图. 4. 神经网络训练阶段

浙江大学 信息与电子工程学院
College of Information Science & Electronic Engineering, Zhejiang University

IB 的仿真验证

利用简单的神经网络 (四个隐藏层，神经元个数分别为：6,4,3,2)，为方便计算，输入数据为随机生成的 10 位二进制数。可以展示神经网络训练过程中各层隐藏层 $I(T;\ X)$，$I(T;\ Y)$ 的关系。

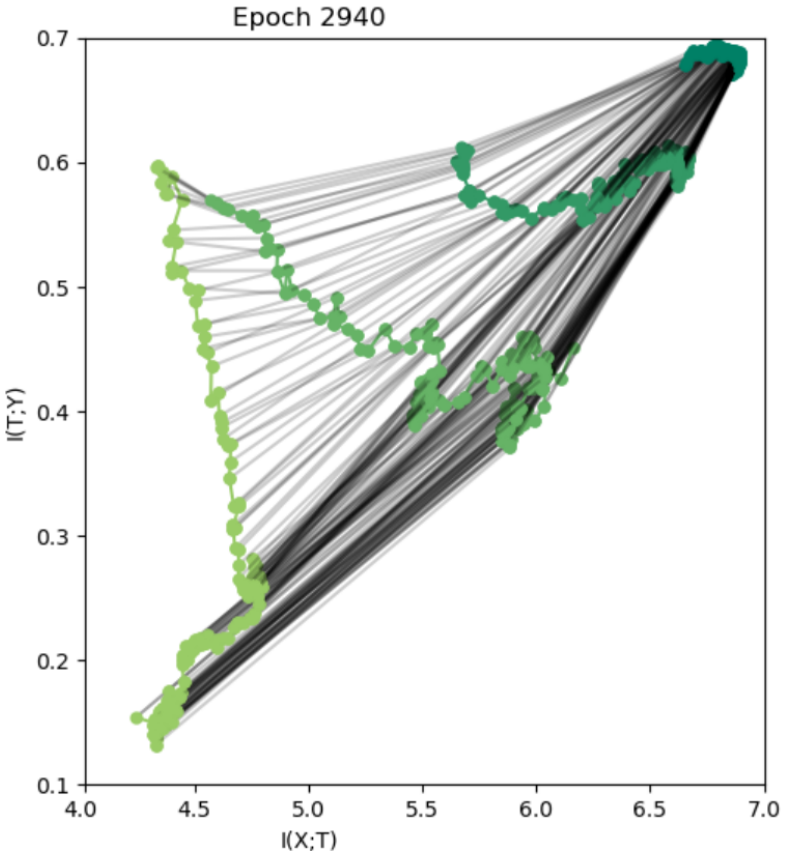

图. 5. 神经网络各层互信息

浙江大学 信息与电子工程学院
College of Information Science & Electronic Engineering, Zhejiang University

IB 的仿真验证

利用 Adam Optimizer 进行优化，可以发现利用更好的优化算法或者不同的神经网络结构，对于各隐藏层的互信息都有明显的影响。

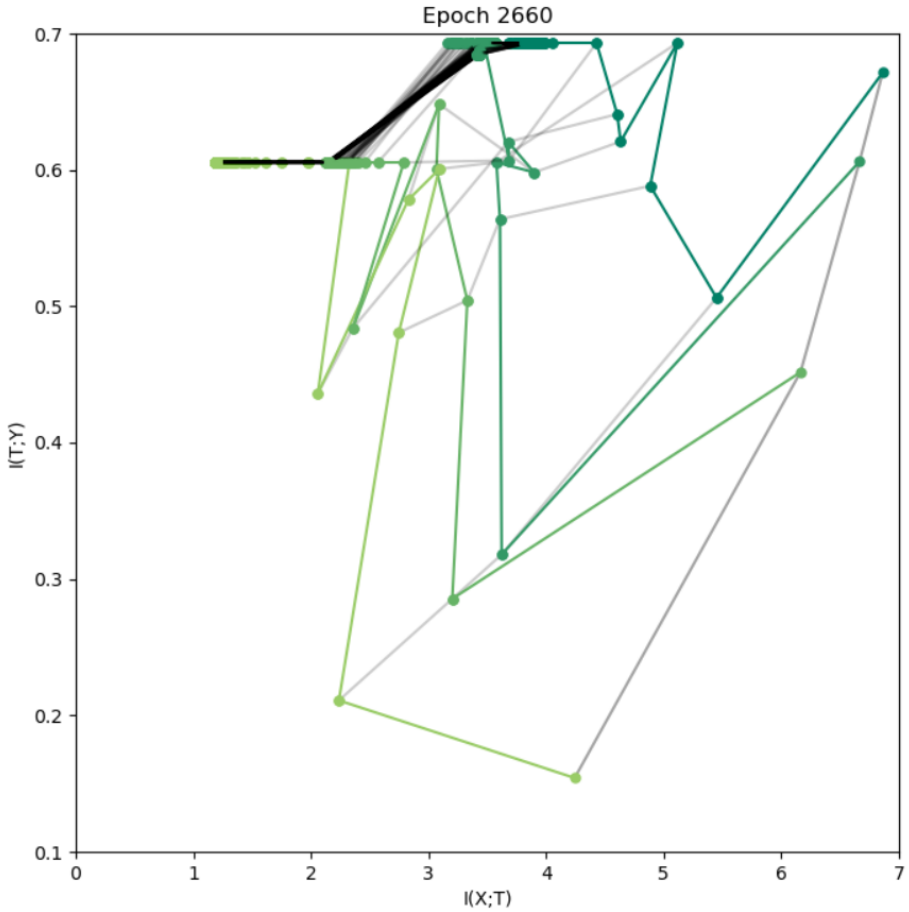

图. 6. 神经网络各层互信息

浙江大学 信息与电子工程学院
College of Information Science & Electronic Engineering, Zhejiang University

IB 的局限性

- IB 局限于简单的前馈型神经网络，无法解释所有模型，如 ResNet 和 Transformer 等。
- 在神经网络中，非线性激活函数的引入使得 IB 的理论推导变得复杂。
- IB 框架中的特征 T 是隐性的，无法通过观测以验证有效性，并推广至实际应用。

Outline 目录

引言

背景

IB 理论

IB 与神经网络

参考文献

浙江大学 信息与电子工程学院
College of Information Science & Electronic Engineering, Zhejiang University

Reference I

- N. Tishby, F. C. Pereira, and W. Bialek, "The information bottleneck method," *arXiv preprint physics/0004057*, 2000.
- N. Tishby and N. Zaslavsky, "Deep learning and the information bottleneck principle," in *2015 IEEE Information Theory Workshop (ITW)*, pp. 1–5, 2015.